



哈爾濱工業大學(深圳)

HARBIN INSTITUTE OF TECHNOLOGY, SHENZHEN



机器学习实验三

—— 基于朴素贝叶斯的中文新闻标题分类

2026年 春

目录



一、实验目标

- **掌握文本分类完整流程：**数据读取与探索 → 文本预处理 → 特征表示 → 模型训练
→ 模型评估与错误分析
- **理解多项式朴素贝叶斯分类器的基本原理**
- **学会使用多维度评价指标**
- **培养实验对比分析能力：**比较不同平滑参数 α 和 n-gram 设置对分类效果的影响
，并理解 BOW 与 TF-IDF 的区别

二、实验任务与数据集

- **任务目标：**基于处理后的**THUCNews新闻标题数据子集**，实现基于朴素贝叶斯的文本分类模型，并系统评估其性能。
- **数据集说明**
 - **来源：**THUCNews（新浪新闻RSS 2005-2011），本实验仅使用新闻标题文本。
 - **数据划分（固定）：**训练集 80000 条，验证集 10000 条，测试集 10000 条。
 - **类别：**14个互斥类别（财经、彩票、房产、股票、家居、教育、科技、社会、时尚、时政、体育、星座、游戏、娱乐）。
 - **文件格式：**每行格式为 新闻标题文本<TAB>类别，UTF-8编码（<TAB>是制表符）。

注意：由于 THUCNews 新闻标题数据集体量较大且存在重复样本，本实验已预先完成数据去重，并对数据集进行精简缩减。

三、实验步骤 - 文本分类一般流程



三、实验步骤 - 环境准备

➤ conda环境准备示例


1. **创建环境** `conda create -n ml_lab3 python=3.10 -y`
2. **激活环境** `conda activate ml_lab3`
3. **安装基础库** `conda install numpy pandas scipy scikit-learn matplotlib jupyter ipykernel -y`
4. **安装 jieba** `pip install jieba`
5. **注册内核** `python -m ipykernel install --user --name ml_lab3 --display-name "Python (ml_lab3)"`

说明：也可以使用之前创建的环境，补装之前没有安装过的库。

三、实验步骤 - 数据读取与类别分布

➤ 统计类别分布

类别	train	dev	test
科技	15549	1944	1944
股票	14482	1810	1810
体育	13250	1656	1656
娱乐	9179	1147	1147
时政	5818	727	727
社会	4772	596	596
教育	3936	492	492
财经	3539	442	442
家居	3063	383	383
游戏	2301	288	288
房产	1798	225	225
时尚	1264	158	158
彩票	749	94	94
星座	300	38	38



三、实验步骤 – 文本预处理

➤ Jieba 分词示例

代码示例

```
import jieba

text = "机器学习实验三基于朴素贝叶斯的文本分类算法"

words = jieba.lcut(text)

print(words)
```

分词结果

输入文本

机器学习实验三基于朴素贝叶斯的文本分类算法



分词后

机器学习 / 实验 / 三 / 基于 / 朴素 / 贝叶斯
/ 的 / 文本 / 分类 / 算法

说明:

- 推荐使用 jieba.lcut(), 直接返回列表, 便于后续处理
- 分词后通常还需要去标点、去停用词、清洗噪声
- 分词结果会作为后续 BOW、TF-IDF 等文本表示方法的输入

三、实验步骤 - 文本表示: BOW词袋模型

词袋模型 (BOW) 示例

假设语料库中有 3 条文本，分词后如下：

d_1 : 机器学习 改变 教育 机器学习 帮助 教学

d₂: 教育 帮助 成长

d_3 : 今天 天气 很好

步骤 1：用整个语料库建立统一词表 Vocabulary

词表 = [机器学习, 改变, 教育, 帮助, 教学, 成长, 今天, 天气, 很好]


步骤 2：统计每条语句中每个词出现的次数

文档-词项矩阵

[illegible]

三、实验步骤- 文本表示: n-gram特征

➤ n-gram 特征参数示例



三、实验步骤 – 文本表示: TF-IDF

➤ TF-IDF 示例

假设语料库中有 3 条文本，分词后如下：

- d₁：机器学习 改变 教育 机器学习 帮助 教学
- d₂：教育 帮助 成长
- d₃：今天 天气 很好



步骤 1：统计每个词在多少篇文档中出现（df），再计算逆文档频率 IDF

$$IDF(w) = \log\left(\frac{N + 1}{df(w) + 1}\right) + 1$$

这里 N = 3

词项	机器学习	改变	教育	帮助	教学	成长	今天	天气	很好
df	1	1	2	2	1	1	1	1	1
IDF	1.69	1.69	1.29	1.29	1.69	1.69	1.69	1.69	1.69



* 示例中 log 使用自然对数；该公式为平滑 IDF 版本。

步骤 2：用 TF × IDF 得到 TF-IDF 权重（以 d₁ 为例）

d₁ 的词频 (TF)

[2, 1, 1, 1, 1, 0, 0, 0, 0]

d₁ 的 TF-IDF 向量


[3.38, 1.69, 1.29, 1.29, 1.69, 0, 0, 0, 0]

例如：机器学习 = 2 × 1.69 = 3.38；教育 = 1 × 1.29 = 1.29

三、实验步骤 – 模型训练

➤ 朴素贝叶斯分类示例

- 问：一篇新闻标题里的词，更像哪个类别里常出现的词？



推理流程：分词 → 统计词在各类别中的出现情况 → 计算每个类别的得分 → 取最大值

三、实验步骤 – 模型训练

➤ 多项式朴素贝叶斯核心公式

1 先验概率

类别本身有多常见

$$P(c) = \frac{N_c}{N}$$

训练集中该类别文档数
/ 总文档数

2 条件概率

词在该类别中有多常见

$$P(w | c) = \frac{\text{count}(w, c) + \alpha}{\sum_{w' \in V} \text{count}(w', c) + \alpha|V|}$$

α 用于平滑, 避免未出现词概率为 0

3 类别得分

把文本中所有词综合起来
, 选择得分最高的类别

$$\text{score}(c) = \log P(c) + \sum_{j=1}^V x_j \log P(w_j | c)$$

x_j 表示词 w_j 在当前文本中出现的次数

三、实验步骤 – 模型训练

➤ 拉普拉斯平滑参数 alpha

alpha 的作用：避免零概率；它改变条件概率 $P(w|c)$ ，因此会影响最终分类。

例子：词频统计

假设 $|V| = 1000$ ，每类总词数约 5000

体育类	股票类
冠军 95	股票 130
球队 80	上涨 90
比赛 120	银行 70
股票 0	球队 0

待分类标题：球队 获得 冠军

加入 alpha 后怎样变化？

$$P(w|c) = (\text{词频} + \alpha) / (\text{该类总词数} + \alpha \times |V|)$$

以“球队”在股票类中词频为 0 为例：

设置	计算	含义
不平滑	$0/5000=0$	直接为0
$\alpha=1$	$(0+1)/(5000+1000)$	有保底概率
$\alpha=10$	$(0+10)/(5000+10000)$	更强平滑

未见过 ≠ 不可能
没有平滑时，一个未出现词会让该类得分被直接拉低。

alpha 不是越大越好
过大时，不同词之间的差异会被“拉平”。

三、实验步骤 – 模型评估

➤ 评价指标

1. Accuracy: 整体分类正确率

$$\text{Accuracy} = \text{预测正确的样本数} / \text{总样本数}$$

看整体是否分类正确

容易受多数类影响

2. Macro-F1: 各类别 F1 的简单平均

$$\text{Macro-F1} = (1/K) \times \sum_i F1_i$$

每个类别权重相同

能发现小类别被忽略

3. Weighted-F1: 按样本数加权平均

$$\text{Weighted-F1} = \sum_i (n_i/N) \times F1_i$$

更接近真实类别分布

多数类权重更大

三、实验步骤 – 模型评估

评价指标

- 假设验证集有 1000 条新闻：科技 700 条、体育 250 条、星座 50 条。

1) 各类别表现

类别	support	预测正确数	F1
科技	700	672	0.94
体育	250	210	0.86
星座	50	0	0.00

support = 该类别在验证集中的样本数

2) 三个整体指标怎么看？

Accuracy 88.2%
多数类占比高，整体看起来不错

Weighted-F1 0.87
按样本数加权，大类别影响更大

Macro-F1 0.60
每类同等权重，小类别问题暴露

分析

如果只看 Accuracy 或 Weighted-F1，容易误以为模型“整体很好”；Macro-F1 会提醒我们**关注少数类**。因此本实验调参主要参考 Macro-F1。

三、实验步骤 - 错误分析与改进

1 发现问题
看哪些类别容易混淆



2 定位原因
抽取错例，观察文本特点



3 改进实验
调整特征、参数或数据

Notebook 中包含: **选做**

A. 混淆矩阵分析

- 绘制真实类别 × 预测类别矩阵
- 找出非对角线最大的类别对
- 观察 “哪些类经常互相误判”

B. 错误样本抽取

- 找到 $y_{\text{true}} \neq y_{\text{pred}}$ 的样本
- 随机抽取若干条错例
- 展示 text/true_label/pred_label

常见错误

- 标题过短，信息不足
- 类别语义相近、边界模糊
- 罕见词、新词或未登录词
- 分词或停用词处理不理想

改进方向

- 特征层面** 加入 n-gram、尝试 TF-IDF、调整 max_features / min_df
- 预处理层面** 补充停用词、用户词典，清洗异常符号和噪声词
- 模型层面** 调节 alpha; 与 Logistic Regression / LinearSVC 对比
- 数据层面** 补充少数类样本，检查标签边界和标注一致性

四、Notebook完成要求

➤ 任务一 sklearn 基线流程

1. 读取数据并检查 train/dev/test; 完成基本 EDA。
2. 完成 jieba 分词、清洗、停用词过滤。
3. 构建 BOW 特征; 词汇表只在训练集 fit。
4. 训练 sklearn MultinomialNB baseline。
5. 在验证集比较 alpha, 并主要参考 Macro-F1。
6. 在验证集比较 n-gram 设置。
7. 选择验证集较优组合, 在测试集最终评估。

➤ 任务二 手写 MyMultinomialNB

1. 补全 MyMultinomialNB 的 TODO。
2. 手写模型完成训练、验证集评估、测试集评估。
3. 分析比较 sklearn 与手写模型在同设置下的结果。

四、Notebook完成要求

➤ 附加题（选做部分）

1. 混淆矩阵可视化。
2. 错误样本分析。
3. BOW 与 TF-IDF 的对比实验。
4. 其他分类器对比：LogisticRegression 或 LinearSVC

每项2-4分，最高加10分，且本次实验总分不超过100分。

实验提交

实验报告提交至平台 <https://grader.hitsz.edu.cn/courses>

注意：

- 1、用户名可用[统一身份登录](#)；
- 2、提交截止时间：**5月29号 晚23点**；补交按得分80%计算分数；
- 3、提交内容：实验报告(.word文件)+代码(.ipynb文件, [重要代码处加注释](#))，一起打成zip包提交。实验报告内容和要求请参考[模板](#)。